Segmentation des lésions ischémiques (AVC) sur IRM

Prédire et réparer l'échec d'un modèle face à un nouvel hôpital

Projet 6 — Domain shift inter-centres · Problématique, solution, état de l'art et valeur ajoutée

En une phrase : apprendre à une IA à délimiter automatiquement les lésions d'AVC sur IRM, et garantir qu'elle reste fiable sur les scans d'un hôpital qu'elle n'a jamais vu, grâce à la mesure du domain shift, à des techniques de généralisation et à une **adaptation continue contrôlée** à chaque nouveau centre.

1. Problématique

Lors d'un AVC ischémique, une partie du cerveau n'est plus irriguée et s'abîme. Sur l'IRM, cette zone (la **lésion**) doit être localisée et mesurée précisément, mais la délimiter à la main sur chaque coupe d'un volume 3D prend beaucoup de temps et demande une expertise en neuroanatomie.

Les modèles d'apprentissage profond savent segmenter ces lésions, mais ils souffrent d'un problème majeur : le **domain shift**. Chaque hôpital utilise ses propres machines, protocoles et résolutions ; un même cerveau n'a donc pas la même apparence d'un centre à l'autre. Un modèle entraîné sur les hôpitaux A, B et C perd souvent en performance sur l'hôpital D.

- La revue systématique de **Baaklini et al. (2025)** (41 études, 2015-2023) conclut à une généralisabilité globalement faible des modèles existants.
- Les scores publiés sont souvent mesurés sur des patients des **mêmes centres** que l'entraînement, ce qui surestime la performance réelle.
- En clinique, un hôpital n'a aucun moyen de savoir **à l'avance** si le modèle fonctionnera sur ses propres scans, ni combien de cas annotés il faudrait pour l'adapter.

Problématique : *comment segmenter automatiquement les lésions ischémiques sur IRM de façon fiable sur des centres jamais vus, prévoir quand le modèle risque d'échouer sur un nouvel hôpital, et l'adapter efficacement avec un minimum de données annotées ?*

Questions de recherche

	Question
RQ1	Comment réduire le domain shift pour qu'un modèle entraîné sur certains centres garde de bonnes performances sur d'autres centres ?
RQ2	Un Transformer 3D généralise-t-il mieux entre centres qu'un U-Net / nnU-Net classique ?
RQ3	Quelles techniques d'augmentation et/ou d'adaptation de domaine réduisent le plus l'écart de performance entre centres ?

2. Solution proposée

Un système de segmentation 3D qui prend une IRM T1 et produit un **masque binaire** de la lésion (pour chaque voxel : lésion ou non), accompagné d'un volume en mL et d'une carte d'incertitude. La solution s'articule en quatre blocs :

Bloc	Rôle
Pipeline Big Data (Spark)	Préparer et analyser en parallèle ~1 450 volumes 3D, et calculer les statistiques par centre
Modèles de segmentation	nnU-Net (baseline) comparé à un Transformer 3D (SwinUNETR)
Généralisation	Augmentation d'intensité, normalisation de Fourier, adaptation adversariale, adaptation au test
Adaptation continue contrôlée	Adapter le modèle à chaque nouvel hôpital de façon sûre, avec validation (valeur ajoutée)

3. Détails de la solution

3.1 Données

Jeu de données	Contenu	Rôle
ISLES'26 — données d'entraînement (NITRC, « ATLAS v3.0 »)	1 453 IRM T1 pondérées, déjà débarrassées du crâne, avec masques de lésion pour tous les sujets. Métadonnées : CENTER, DAYS_POST_STROKE, CHRONICITY. Stades aigu, sub-aigu et chronique.	Jeu principal. Le code CENTER permet les découpages par hôpital.
ATLAS v2.x — version normalisée (MNI-152)	Mêmes 955 cas ATLAS, recalés sur un cerveau de référence, intensité normalisée	Expérience optionnelle : le recalage réduit-il l'écart entre centres ?
ISLES'22 (Zenodo)	250 cas publics en diffusion (DWI/ADC/FLAIR)	Optionnel : test inter-modalités

*Le challenge ISLES'26 est clôturé (soumissions fermées le 19 août 2026) mais les données d'entraînement restent téléchargeables. On utilise la version **brute** (« Raw Data »), qui conserve les différences entre hôpitaux, cœur du sujet.*

3.2 Pipeline Big Data avec Spark

Chaque volume 3D est un fichier NIfTI (.nii.gz), c'est-à-dire une matrice 3D de valeurs d'intensité, accompagnée d'un masque de même taille (1 = lésion, 0 = sain). Spark distribue le traitement des patients sur tous les cœurs disponibles :

Étape	Traitement	Pourquoi
1. Inventaire	Lecture des métadonnées JSON → table Parquet (patient, centre, délai post-AVC, chemins)	Base de toute l'analyse
2. Réorientation	Orientation standard (RAS)	Scans stockés tournés ou inversés
3. Rééchantillonnage	Voxels de 1 × 1 × 1 mm (masque : plus proche voisin)	Résolutions différentes selon les centres
4. Correction N4 (option)	Correction du biais de champ	Luminosité inhomogène selon le scanner
5. Normalisation	Z-score dans le masque du cerveau	Échelles d'intensité différentes
6. Recadrage	Suppression de l'espace vide autour du cerveau	Fichiers plus légers, entraînement plus rapide
7. Contrôle qualité	Détection des masques vides, tailles aberrantes, fichiers corrompus	Fiabilité des données

Étape	Traitement	Pourquoi
8. Statistiques par centre	Histogrammes d'intensité, résolutions, volumes lésionnels	Visualiser et quantifier le domain shift

Spark sert à la préparation et à l'analyse ; l'entraînement se fait avec PyTorch sur GPU. Un benchmark du temps de traitement avec 1, 2, 4 et 8 cœurs démontre le passage à l'échelle (Dritsas et al., 2025).

3.3 Découpage des données par centre

C'est la décision la plus importante du projet : on découpe **par hôpital**, pas par patient.

- **In-distribution (ID) :** entraînement et test sur des patients différents des mêmes centres.
- **Out-of-distribution (OOD) :** des centres entiers sont retirés de l'entraînement et servent uniquement au test.
- **Validation croisée leave-centers-out :** K-fold groupé où chaque groupe est un centre.
- Mesure centrale : **écart de généralisation = Dice(ID) − Dice(OOD)**.

3.4 Modèles

Modèle	Description	Question
nnU-Net v2 (3D full resolution)	Réseau qui se configure automatiquement ; baseline de référence	RQ1
SwinUNETR (MONAI)	Transformer 3D, poids pré-entraînés auto-supervisés disponibles	RQ2
UNETR	Transformer 3D plus simple, point de comparaison	RQ2
MedNeXt (option)	ConvNet moderne : le gain vient-il de l'attention ou de la modernité ?	RQ2
DeepISLES (référence)	Ensemble validé cliniquement issu d'ISLES'22	Comparaison externe

Les deux familles de modèles reçoivent exactement les **mêmes données prétraitées** et les mêmes découpages, pour une comparaison équitable. Entraînement par patchs (ex. 128^3) et précision mixte pour tenir en mémoire GPU.

3.5 Techniques de généralisation (RQ3)

Famille	Techniques	Idée
Augmentation d'intensité	Gamma, contraste, bruit, flou, biais de champ simulé, basse résolution simulée	Rendre le modèle insensible aux différences de scanner
Randomisation du style	Convolutions aléatoires, GIN, BigAug	Changer le « style » de l'image en gardant l'anatomie
Méthodes de Fourier	Fan-Net, FDA (échange d'amplitude basse fréquence)	Le style du scanner vit surtout dans les basses fréquences
Adaptation adversariale	DANN (inversion de gradient + classifieur de centre)	Apprendre des caractéristiques indépendantes du centre
Adaptation au test	TENT (mise à jour des couches de normalisation)	S'adapter au nouveau centre sans étiquettes
Harmonisation	Histogram matching vers un centre de référence	Baseline simple de prétraitement

Un **tableau d'ablation** présente, pour chaque combinaison : Dice ID, Dice OOD et écart.

3.6 Évaluation

- Métriques ISLES : **Dice**, **distance de Hausdorff 95 %**, différence absolue de volume, F1 par lésion, différence du nombre de lésions.
- Tests statistiques : Wilcoxon signé entre méthodes, intervalles de confiance par bootstrap.
- Résultats stratifiés : par centre, par taille de lésion, par stade (aigu, sub-aigu, chronique).
- Analyse des échecs : quels centres échouent et pourquoi, en lien avec les statistiques de l'étape Spark.

3.7 Démonstration

Une application **Gradio** ou **Streamlit** : on charge une IRM, on voit les coupes avec la lésion colorée, et un **mini-rapport clinique** : volume de la lésion en mL, régions cérébrales touchées (via un atlas), niveau d'incertitude, et alerte « scan hors distribution » si le centre est trop différent des données d'entraînement. Visualisation 3D interactive possible avec NiiVue.

3.8 Technologies et ressources

Domaine	Outils
Apprentissage profond	Python, PyTorch, MONAI, nnU-Net v2, TorchIO
Traitement IRM	nibabel, SimpleITK, ANTsPy
Big Data	PySpark, Parquet
Suivi et reproductibilité	MLflow ou Weights & Biases, Docker, Git, DVC
Visualisation	ITK-SNAP, 3D Slicer, matplotlib, NiiVue
Démo	Gradio ou Streamlit
Calcul	Spark en local (CPU) ; GPU Kaggle (~30 h/semaine, T4/P100) et/ou AWS étudiant pour l'entraînement

4. Solutions existantes

Travail	Approche	Limite
DeepISLES (de la Rosa et al., 2024-2025)	Ensemble des meilleurs modèles d'ISLES'22, validé sur 1 685 cas externes	IRM de diffusion ; modèle figé, sans mécanisme d'adaptation à un nouveau centre
ISLA (Roca et al., 2026)	U-Net avec supervision profonde, attention, adaptation de domaine non supervisée, ensemble	Adaptation ponctuelle ; ne prédit pas à l'avance l'échec sur un centre
Rangel et al. (2025)	Apprentissage fédéré sur 14 centres simulés (2 031 études)	Nécessite la participation et l'infrastructure de chaque centre
Fan-Net (Yu et al., 2023)	Normalisation adaptative dans le domaine de Fourier, testée sur ATLAS (9 sites)	Une seule famille de techniques, peu de centres
nnU-Net (Isensee et al.)	Configuration automatique, référence en segmentation médicale	Aucune stratégie spécifique contre le domain shift
Baaklini et al. (2025)	Revue systématique et méta-analyse (41 études)	Constate la faible généralisabilité, sans proposer de solution

Constat : les techniques d'adaptation de domaine existent, mais elles sont souvent testées isolément, sur peu de centres, et produisent un modèle **figé**. Aucune ne répond aux deux questions pratiques d'un hôpital : *« le modèle va-t-il marcher chez nous ? »* et *« combien de cas faut-il annoter pour l'adapter ? »*.

5. Valeur ajoutée

5.0 Limites d'un réentraînement naïf sur les scans à analyser

Réentraîner automatiquement le modèle sur chaque nouvelle IRM qu'on lui donne à analyser pose quatre problèmes, particulièrement graves en médecine :

- **Pas de masque de référence au moment de la prédiction.** Le modèle devrait apprendre de son propre masque : s'il rate une lésion, il apprend à la rater.
- **Évaluation faussée.** Apprendre sur les données de test puis être noté dessus gonfle le Dice.
- **Oubli catastrophique.** En s'adaptant à un hôpital, le modèle peut se dégrader sur les autres.
- **Contrainte réglementaire.** Un logiciel médical ne peut pas modifier son comportement sans validation.

Le projet propose donc une version contrôlée de cette adaptation, qui constitue sa contribution principale :

5.1 Contribution principale : adaptation continue contrôlée à chaque nouveau centre

On simule l'arrivée successive de nouveaux hôpitaux (centres OOD présentés un par un). Pour chacun :

Mécanisme	Fonctionnement
1. Détection du décalage	À l'arrivée des premiers scans, le système mesure la distance entre ce centre et les données d'entraînement (histogrammes d'intensité, caractéristiques internes du réseau) et estime le risque d'échec.
2. Adaptation immédiate sans étiquettes	Adaptation au test (TENT) : seules les couches de normalisation sont ajustées aux statistiques du nouveau centre. Aucun masque n'est nécessaire.
3. Apprentissage actif avec le radiologue	Le système sélectionne les scans les plus incertains et demande au radiologue de corriger leurs masques. Seuls ces masques validés servent au réentraînement (fine-tuning).
4. Évaluer d'abord, apprendre ensuite	Chaque nouveau lot est d'abord prédit et noté, puis seulement utilisé pour l'entraînement (évaluation préquentielle) : le score reste honnête.
5. Champion / challenger	Le modèle adapté ne remplace l'ancien que s'il fait mieux sur des cas validés du nouveau centre **et** ne se dégrade pas sur les anciens centres.
6. Mémoire des anciens centres	Un échantillon des anciens centres (replay buffer) est rejoué pendant l'adaptation pour éviter l'oubli catastrophique.

Résultat à présenter : pour chaque nouveau centre, une courbe comparant quatre stratégies :

- modèle figé (jamais adapté) ;
- auto-apprentissage naïf sur ses propres prédictions : instable ;
- adaptation au test seule (sans étiquettes) ;
- adaptation continue contrôlée : meilleur Dice sur le nouveau centre sans perte sur les anciens.

5.2 Prédire l'échec avant qu'il se produise

On mesure à quel point chaque centre « ressemble » aux données d'entraînement, puis on vérifie si cette distance **prédit la chute du Dice**. Résultat : un graphique « distance du centre » contre « perte de performance ». Un hôpital peut ainsi savoir si le modèle fonctionnera chez lui **sans rien annoter**. C'est aussi ce qui déclenche l'alerte dans la démo.

5.3 Combien de scans annotés faut-il à un nouvel hôpital ?

Pour un centre jamais vu, on adapte le modèle avec 0, 1, 5, 10 et 20 scans annotés et on trace la récupération du Dice. Exemple de conclusion attendue : *« avec 5 scans annotés, l'écart se réduit de X % »*. Une réponse directement utile aux hôpitaux.

5.4 Le temps comme second domain shift

ISLES'26 couvre les stades aigu, sub-aigu et chronique, avec le délai post-AVC dans les métadonnées. On compare deux décalages : **où** le scan a été acquis (centre) et **quand** (âge de la lésion). Bonus : fournir le délai post-AVC au modèle comme entrée supplémentaire.

5.5 Test de l'empreinte du centre

Un petit classifieur essaie de deviner **de quel hôpital** vient un scan. S'il y parvient, le centre laisse une empreinte dans l'image. Après augmentation ou DANN, s'il n'y parvient plus, on montre **pourquoi** la technique fonctionne, et pas seulement qu'elle améliore le Dice.

5.6 Diversité contre quantité (option)

Comparer 500 scans issus de 5 centres et 500 scans issus de 30 centres, testés sur des centres jamais vus. Si le jeu diversifié gagne, on démontre que **la diversité compte plus que la quantité**.

6. Planning indicatif

Semaines	Travail	Livrable
1-2	Accès aux données, environnement, exploration par centre	Statistiques et histogrammes par centre
2-4	Pipeline Spark de prétraitement, découpages par centre	Données propres + benchmark Spark
4-6	Baseline nnU-Net	Écart ID / OOD (RQ1)
6-8	SwinUNETR, UNETR	Comparaison des architectures (RQ2)
8-11	Techniques de généralisation + adaptation continue contrôlée	Tableau d'ablation (RQ3), courbes d'adaptation
11-12	Prédiction d'échec, courbe few-shot, analyses	Graphiques de valeur ajoutée
12-14	Démo, rapport, présentation	Application + rapport final

7. Synthèse

Élément	Contenu
Problème	Les modèles de segmentation d'AVC perdent en performance sur les hôpitaux jamais vus
Solution	Pipeline Spark + nnU-Net vs. Transformer 3D + techniques de généralisation, évalués par centre
Contribution principale	Adaptation continue contrôlée à chaque nouveau centre : détection du décalage, TENT, apprentissage actif avec radiologue, préquentiel, champion/challenger, replay
Contributions secondaires	Prédiction de l'échec, courbe few-shot, décalage temporel, empreinte du centre
Livrables	Pipeline Spark, modèles, tableau d'ablation, courbes d'adaptation, démo avec rapport clinique, rapport

> **Titre proposé :** *Segmentation des lésions d'AVC sur IRM : prédire et réparer l'échec inter-centres par adaptation continue contrôlée*

Sources

- ISLES'26 — isles-26.grand-challenge.org (présentation et page « Dataset »)
- Données : fcon_1000.projects.nitrc.org/indi/retro/atlas.html
- Liew, S.-L. et al. (2022). ATLAS v2.0. *Scientific Data*, 9, 320
- de la Rosa, E. et al. DeepISLES. *Nature Communications* (2025)
- Roca, V. et al. (2026). ISLA. arXiv
- Rangel, E. et al. (2025). Federative ischemic stroke segmentation. arXiv
- Yu, W. et al. (2023). Fan-Net. ICASSP 2023
- Baaklini, M. et al. (2025). *Frontiers in Medical Technology*
- Dritsas, E. et al. (2025). Applying Machine Learning on Big Data With Apache Spark. *IEEE Access*
- Hernandez Petzsche, M. et al. (2022). ISLES 2022 dataset. *Scientific Data*